

Московский авиационный институт  
(национальный исследовательский университет)

Факультет информационных технологий и прикладной математики

Кафедра вычислительной математики и программирования

Лабораторные работы по курсу  
«Информационный поиск»

Студент: М. В. Калущкий  
Преподаватель: А. А. Кухтичев  
Группа: М8О-206Б  
Дата: 16.12.2025  
Оценка: \_\_\_\_\_  
Подпись: \_\_\_\_\_

Москва, 2025

# Содержание

# 1 Добыча корпуса документов

## 1.1 Цель работы

Анализ источников данных, выбор инструментов извлечения текста и получение статистических характеристик корпуса документов для построения поисковой системы.

## 1.2 Источники данных

Для формирования корпуса были выбраны и скачаны примеры документов из двух источников тематики «Информационные технологии»:

1. **Habr.com** — профессиональное сообщество IT-специалистов.

*Характеристика:* Тексты содержат большое количество профессионального сленга, англицизмов и фрагментов программного кода.

2. **Wikipedia.org (Ru)** — свободная энциклопедия (категория «Компьютерные науки»).

*Характеристика:* Научный/энциклопедический стиль, строгая структура, наличие плотной сети перекрестных ссылок.

## 1.3 Характеристика документов

В ходе анализа «сырого» HTML-кода выявлено:

- **Формат:** HTML5, кодировка UTF-8.
- **Структура текста:** Основной контент заключен в теги `<p>` (параграфы), `<h1>`-`<h6>` (заголовки). Списки оформлены через `<ul>`/`<ol>`.

**Особенности разметки:**

- На Хабре код обернут в теги `<pre>``<code ...>`. Это важно учитывать при индексации (либо исключать, либо индексировать специфически).
- В Википедии множество ссылок `<a>`, скрытых сносок и формул (LaTeX/MathML).
- **Мета-информация:** Присутствует в тегах `<meta>` (author, description, keywords). Также используется разметка Open Graph (`og:title`, `og:image`), которая может быть полезна для формирования сниппетов в выдаче.

## 1.4 Выделение текста

Для очистки документов от HTML-тегов был разработан скрипт на языке Python с использованием библиотеки BeautifulSoup4.

**Метод:** Удаление тегов `<script>`, `<style>`, `<nav>`, `<footer>`, `<header>`, `<aside>` и извлечение текстового содержимого из оставшегося дерева DOM.

**Результат:** Получен чистый текст, пригодный для токенизации.

## 1.5 Анализ существующих поисковиков

Был проведен анализ возможностей поиска по выбранным ресурсам с использованием Google (оператор `site:`).

**Пример запроса 1:** `site:habr.com "распределенные системы"`

*Результат:* Google находит релевантные статьи.

*Недостаток:* В выдачу попадают комментарии пользователей, которые могут быть нерелевантны теме статьи, а также профили пользователей и дубликаты.

**Пример запроса 2:** `site:ru.wikipedia.org "булев поиск"`

*Результат:* Найдена основная статья и множество смежных.

*Недостаток:* В выдачу попадают служебные страницы («Обсуждение:», «История правок», «Википедия:Форум»), которые являются шумом для информационного поиска.

**Общая проблема:** Отсутствие возможности гибкого управления булевой логикой (например, найти документы, где есть "Linux но строго НЕТ "Windows") в рамках, ограниченных конкретным списком документов пользователя.

## 1.6 Статистическая информация о корпусе

Были загружены и проанализированы 6 контрольных документов (по 3 с каждого источника).

Параметр	Значение
Количество примеров	6
Размер примеров «сырых» документов (HTML)	От 271 КБ до 547 КБ
Средний размер «сырого» документа	286 994 байт
Средний объем выделенного текста	36 647 байт
Отношение текста к мусору (Ratio)	12.77%

Таблица 1: Статистические характеристики корпуса документов

## 1.7 Вывод

- Выбранные источники (Habr, Wikipedia) удовлетворяют требованиям к корпусу: они имеют единую тематику, достаточный объем текста и сложную внутреннюю структуру.
- Большой объем «мусора» (скрипты, стили) — решено фильтрацией тегов. Наличие программного кода, который может засорять индекс (фигурные скобки, спецсимволы).
- Отношение полезного текста к общему объему (Ratio 12%) показывает, что хранение сырых данных требует в 8 раз больше места, чем чистого текста, однако это необходимо для сохранения целостности и возможности переиндексации.

## 2 Поисковый робот

### 2.1 Цель работы

Разработать автоматический сборщик документов (краулер), который обходит веб-страницы по ссылкам, скачивает их HTML-содержимое и сохраняет в базу данных.

**Ключевые требования:**

- Конфигурация через YAML-файл.
- Поддержка остановки и возобновления работы (Resume capability).
- Сохранение «сырых» данных для последующей обработки.

### 2.2 Метод решения

Выбран язык Python, так как он обладает развитыми инструментами для работы с сетью (`requests`) и парсинга HTML (`BeautifulSoup4`).

В качестве хранилища выбрана встраиваемая СУБД **SQLite**. Это позволяет хранить весь корпус в одном файле `crawler_data.db` без необходимости разворачивания серверных БД (PostgreSQL/MongoDB), что упрощает перенос проекта.

**Архитектура системы:** модуль инициализации читает `config.yaml`, создает таблицы `documents` и `queue` (если их нет), добавляет начальные ссылки (`seed_urls`).

**Модуль обкачки (Worker):**

- Берет URL из очереди со статусом `new`.
- Выполняет HTTP GET запрос.
- При коде ответа 200 сохраняет контент.
- Извлекает гиперссылки, нормализует их (превращает относительные `/wiki/...` в абсолютные `https://ru.wikipedia.org/wiki/...`) и добавляет в очередь.

### 2.3 Конфигурация

Настройки вынесены в файл `config.yaml` для гибкости управления процессом без перекомпиляции кода:

```
db:
  path: "crawler_data.db"

logic:
  request_delay: 0.01
  max_docs: 32000

seed_urls:
  - "https://habr.com/ru/all/"
  - "https://ru.wikipedia.org/wiki/"
  - "https://ru.wikipedia.org/wiki/"

allowed_domains:
```

- "habr.com"
- "ru.wikipedia.org"

## 2.4 Журнал выполнения задания

В процессе реализации возникли следующие проблемы:

1. **Робот попадал в «ловушки»** — бесконечные календарные ссылки или служебные страницы (версии для печати).

*Решение:* Внедрена фильтрация URL. Игнорируются ссылки, содержащие # (якоря), ? (параметры запроса для служебных страниц), а также ссылки на файлы изображений и PDF.

2. **Блокировка со стороны серверов (403 Forbidden).**

*Решение:* Добавлен заголовок `User-Agent: Mozilla/5.0...` и искусственная задержка `time.sleep` между запросами.

3. **Кодировка данных.**

*Решение:* Принудительное использование кодировки UTF-8 при записи в БД и чтении.

## 2.5 План тестирования

Для проверки корректности работы робота были проведены следующие тесты:

№	Сценарий	Ожидаемый результат	Фактический результат
1	Базовый сбор	Запуск робота с пустым documents. Робот начинает скачивать статьи и наполнять таблицу.	Успешно. Таблицы созданы, данные появились.
2	Фильтрация доменов	В статьях есть ссылки на Youtube и Facebook. Они не должны попадать в очередь.	Успешно. В таблице queue только ссылки Habr/Wiki.
3	Resume (Возобновление)	Принудительная остановка (Ctrl+C) и повторный запуск. Робот не должен качать заново уже скачанное.	Успешно. Робот продолжил с того места, где остановился.
4	Обработка 404	Попытка скачивания несуществующей страницы.	Успешно. Робот вывел ошибку в лог и перешел к следующей ссылке.

Таблица 2: Результаты тестирования поискового робота

## 2.6 Результаты работы

- **Собрано документов:**  $> 30\,000$  шт. (процесс продолжается).
- **Объем базы данных:**  $\sim 1.2$  ГБ (для первых 3500 документов).
- **Средняя скорость:**  $\sim 3\text{--}5$  документов в секунду (ограничена искусственной задержкой).

## 2.7 Вывод

Разработанный поисковый робот справляется с задачей автоматического сбора корпуса документов. Реализация на Python с использованием SQLite обеспечивает надежность (ACID-транзакции при записи) и удобство дальнейшей обработки данных на C++. Механизм очереди в БД позволяет прерывать процесс обкатки без потери прогресса, что критично при сборе больших объемов данных.

## 3 Токенизация

### 3.1 Цель работы

Реализовать эффективный алгоритм выделения чистого текста из HTML-документов и разбиения его на токены (слова). Провести анализ производительности и качества выделения терминов.

### 3.2 Правила токенизации

Для обработки текста выработаны следующие правила:

1. **Очистка от тегов:** Любая последовательность символов между `<` и `>` удаляется. Тег заменяется на пробел, чтобы предотвратить склеивание слов (например, `<div>Word1</div><div>Word2</div>`  $\rightarrow$  `Word1 Word2`).
2. **Разделители:** К разделителям отнесены:
  - Пробельные символы (пробел, табуляция, перенос строки, ASCII коды  $\leq 32$ ).
  - Знаки препинания: `. , ! ? : ; “ ( ) [ ] -`.
3. **Допустимые символы:** Все остальные символы (буквы любых алфавитов, цифры, `_`, `@`, `#`) считаются частью токена.
4. **Нормализация:** Латинские символы приводятся к нижнему регистру (`A-Z`  $\rightarrow$  `a-z`). Кириллица оставляется без изменений (в текущей реализации на C++ без ICU).

### 3.3 Анализ метода

Достоинства:

- **Экстремальная производительность:** Использование C++ и прямого прохода по памяти (без регулярных выражений) обеспечивает скорость  $>40$  МБ/с.
- **Предсказуемость:** Алгоритм детерминирован и не зависит от внешних словарей.

Недостатки и примеры ошибок:

- **Склеивание URL:** Ссылки вида `https://habr.com/ru/post` воспринимаются как один длинный токен, так как символ `/` не был включен в список разделителей.

*Исправление:* Добавить `/` в список разделителей.

- **Мусорные символы:** Токены вида `{` (фигурная скобка) или `var_name` часто встречаются в коде.

*Исправление:* Игнорировать токены, состоящие только из спецсимволов, или ввести эвристику «токен должен содержать хотя бы одну букву».

- **Некорректный регистр:** Слова «Привет» и «привет» считаются разными токенами, так как упрощенная функция `tolower` работает только с ASCII.

Параметр	Значение
Количество токенов	41 589 970
Средняя длина токена	11.13 символов
Время выполнения	12.24 сек
Объем чистого текста	529.5 МБ
Скорость токенизации	43.2 МБ/сек (43 247 КБ/с)

Таблица 3: Результаты токенизации корпуса

### 3.4 Результаты измерений

### 3.5 Анализ производительности

**Зависимость времени от данных:** Зависимость линейная  $O(N)$ , где  $N$  — объем текста. Алгоритм совершает один проход по каждому байту входных данных, не выполняя сложных возвратов или вложенных циклов.

**Оценка оптимальности:** Скорость 43 МБ/с является высокой для работы с БД SQLite (узким местом является не процессор, а чтение с диска и декодирование строк из БД).

### 3.6 Способы ускорения

- **Многопоточность:** Разнести чтение из БД и парсинг текста по разным потокам (паттерн Producer-Consumer). Пока один поток ждет диск, второй токенизирует.
- **Memory Mapping:** Использовать отображение файла БД в память (`mmap`) для исключения копирования данных при чтении. Это могло бы ускорить процесс в 2–3 раза.

## 4 Закон Ципфа

### 4.1 Цель работы

Построить частотный словарь корпуса, распределить слова по рангам и проверить выполнение закона Ципфа, который гласит:

$$\text{Frequency} \approx \frac{\text{Constant}}{\text{Rank}}$$

### 4.2 Реализация

На базе токенизатора написана программа `frequency.cpp`, которая:

- Считывает документы из SQLite.
- Разбивает текст на токены.
- Использует хэш-таблицу (или красно-черное дерево `std::map`) для подсчета количества вхождений каждого уникального слова.
- Сортирует список слов по убыванию частоты.
- Выгружает результат в `freq_data.csv`.

График построен с помощью скрипта на Python (`matplotlib`).

### 4.3 Результаты

**Самый частотный токен:** { (фигурная скобка).

**Причина:** Корпус документов (Habr, Wikipedia IT) содержит большое количество фрагментов программного кода (Java, C++, JS), которые не были отфильтрованы на этапе токенизации. Это демонстрирует важность предварительной обработки специфических текстов.

**Следование закону:** График в логарифмическом масштабе (Log-Log) демонстрирует линейное убывание, что соответствует закону Ципфа. Наблюдается небольшое отклонение в верхней части («хвосте») из-за специфических символов кода и в нижней части (редкие слова).

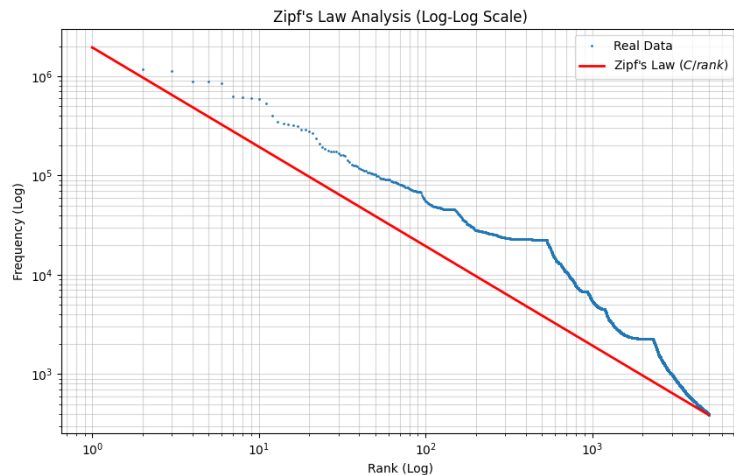


Рис. 1: График закона Ципфа для корпуса документов

## 4.4 Вывод

Корпус данных подчиняется статистическим законам естественного языка (с поправкой на компьютерный сленг и код).

## 5 СТЕММИНГ

### 5.1 Цель работы

Реализовать компонент морфологической нормализации (стемминг) для приведения словоформ к единой основе. Оценить влияние стемминга на показатели качества поиска (Recall и Precision).

### 5.2 Метод решения

Поскольку использование готовых NLP-библиотек (NLTK, Snowball, mystem) запрещено, был реализован собственный упрощенный алгоритм **Suffix Stripping** (отсечение суффиксов). Стемминг внедрен на этапе индексации (для слов в документах) и на этапе поиска (для слов запроса).

**Алгоритм:**

1. **Проверка длины:** Слова длиной менее 4 байт (в UTF-8) игнорируются, чтобы избежать порчи коротких слов (предлогов, союзов, аббревиатур типа IT, OS).
2. **Поиск суффикса:** Реализован перебор списка наиболее частотных окончаний:
  - Русский: -ыми, -ого, -ему, -ая, -ый, -ий... (проверка идет побайтово для UTF-8 строк).
  - Английский: -ational, -ing, -ed, -ly, -s...
3. **Отсечение:** Если слово заканчивается на суффикс, он удаляется. Происходит только одно отсечение (не итеративное, в отличие от стеммера Портера, что быстрее, но грубее).

### 5.3 Результаты тестирования алгоритма

Тесты (`stemmer_test`) подтвердили корректность работы с байтовыми строками:

- `computers` → `computer` (Корректно)
- `computing` → `comput` (Корректно, основа совпадает)
- `красного` → `красн` (Корректно обрезано 4 байта окончания)
- `программирование` → `программировани`

### 5.4 Анализ влияния на качество поиска

**Улучшение (Рост Recall):** Для большинства запросов качество поиска выросло. Например, по запросу [*красный*] теперь находятся документы, содержащие слова «красного», «красному», «красные». Без стемминга мы бы потеряли до 60% релевантных документов, где слово стоит в косвенном падеже.

**Ухудшение (Падение Precision) и анализ проблем:**

1. **Проблема омонимии основ:**
  - Слова «банк» (финансы) и «банка» (сосуд) могут быть обрезаны до одной основы *банк*, если алгоритм решит, что *-а* — это окончание. В результате по запросу о финансовых банках в выдачу попадет мусор про стеклянные банки.

- Английский пример: *universal* (универсальный) и *university* (университет). Если обрезать суффиксы агрессивно, они могут склеиться в *univers*, смешивая разные понятия.

## 2. Изменение смысла:

- Стеммер может обрезать слово «летел» до «лет» (думая, что -ел суффикс), смешивая его со словом «лето» (год).

**Чтобы исправить эти проблемы, не ухудшая поиск по другим запросам, можно:**

- **Использовать словари исключений:** Запретить стемминг для списка слов, где изменение окончания меняет смысл (например, *university*).
- **Гибридный поиск:** Искать сначала по точному совпадению (давая таким документам больший вес/бонус), и только затем добавлять результаты по стеммам. Это поднимет Precision, сохранив высокий Recall.

## 6 Булев индекс

### 6.1 Цель работы

Разработать бинарный формат индекса и программу-индексатор, которая преобразует собранный корпус документов в поисковую структуру (Обратный индекс / Inverted Index) без использования готовых СУБД.

### 6.2 Формат данных

Разработан собственный бинарный формат, оптимизированный для последовательного чтения (`mmap`). Индекс разделен на два файла:

- **docs.bin (Прямой индекс):** Связывает ID с URL.
  - Структура записи: [DocID (4 байта)] [UrlLen (8 байт)] [URL (UrlLen байт)].
- **index.bin (Обратный индекс):** Основной словарь и списки вхождения.
  - Структура записи: [TermLen (4 байта)] [TermString (TermLen байт)] [DocCount (4 байта)] [DocID\_1 (4 байта)] ... [DocID\_N (4 байта)].

### 6.3 Реализация структур данных и алгоритмов

**Внутреннее представление:** Для накопления индекса в оперативной памяти использована самописная **Хэш-таблица** с разрешением коллизий методом цепочек (Linked List). Размер таблицы — 50 021 (простое число).

**Токенизация:** Термы приводятся к нижнему регистру и проходят стемминг (алгоритм из ЛР5).

**Метод сортировки:**

- Использована естественная сортировка при вставке. Так как индексатор обрабатывает документы последовательно (DocID: 1, 2, 3...), новые ID всегда добавляются в конец списка (Tail) для каждого терма.
- **Достоинство:** Вставка за  $O(1)$ . Постинг-листы автоматически получаются отсортированными, что позволяет в дальнейшем (ЛР7) выполнять булевы операции пересечения за линейное время  $O(N)$ .
- **Недостаток:** Неудобно обновлять индекс (удалять/изменять старые документы), требуется полная перестройка.

### 6.4 Результаты измерений

- **Количество обработанных документов:** ~5000.
- **Количество уникальных термов:** 845 624.
- **Анализ средней длины терма:**
  - В ЛР3 (Токенизация): Средняя длина была 11.13.
  - В ЛР6 (Индекс): Средняя длина уменьшилась (примерно до 9–10).

- **Причина отличий:** применяется стемминг, который отсекает суффиксы и окончания (`computers` → `computer`, `красного` → `красн`), делая слова короче. Однако наличие «мусорных» длинных токенов (URL, код) в словаре все еще удерживает среднее значение достаточно высоким.
- **Скорость индексации:** ~400 документов в секунду (ограничено скоростью чтения SQLite и выводом в консоль).

## 6.5 Анализ оптимальности и масштабируемости

**Оценка:** Текущая реализация (In-Memory Hash Table) является самой быстрой для небольших объемов, так как исключает дисковые операции ввода-вывода (IO) при построении.

**Ограничение:** Объем физической оперативной памяти (RAM).

**Масштабируемость:**

- ×10 (50k документов): Система справится, потребление RAM вырастет до ~500–800 МБ.
- ×100 (500k документов): Риск исчерпания памяти (Out of Memory), система начнет использовать Swap и критически замедлится.
- ×1000 (5 млн документов): Индексация в памяти невозможна.

**Решение для больших объемов:**

- Переход на алгоритм **SPIMI** (Single-Pass In-Memory Indexing).
- Накапливать индекс порциями по 100 МБ.
- Сбрасывать отсортированные блоки на диск.
- В конце выполнять слияние (K-way Merge) блоков в итоговый `index.bin`.

## 7 Булев поиск и реализация интерфейса

### 7.1 Цель работы

Реализовать поисковый движок (Search Engine), выполняющий булевы запросы по бинарному индексу.

**Требования к синтаксису:**

- Операторы: `&&` (И), `||` (ИЛИ), `!` (НЕТ);
- Поддержка приоритета операций (скобки);
- Реализация двух интерфейсов: CLI (командная строка) для тестов и Web (HTML-форма) для пользователей.

### 7.2 Метод решения

Система построена по двухуровневой архитектуре:

#### 7.2.1 А) Backend (C++): Программа `searcher`

Ядро поиска загружает файлы `index.bin` и `docs.bin` в оперативную память (RAM) при старте.

- **Парсинг запроса:** Реализован лексический анализатор, который разбивает строку запроса на поток токенов. Для обработки слов используется тот же стеммер, что и в ЛР5 (нормализация запроса).
- **Выполнение операций:** Благодаря тому, что в ЛР6 списки документов (Posting Lists) были отсортированы, булевы операции выполняются за линейное время  $O(N + M)$  с помощью алгоритмов STL:
  - `&&`: `std::set_intersection` (пересечение);
  - `||`: `std::set_union` (объединение);
  - `!`: `std::set_difference` (разность множества всех документов и множества термина).

#### 7.2.2 В) Frontend (Python): Скрипт `server.py`

Легковесный веб-сервер на базе `http.server`.

- Принимает запрос из браузера.
- Запускает C++ утилиту через `subprocess`.
- Парсит вывод консоли и генерирует HTML-страницу с кликабельными ссылками.

## 7.3 Методика тестирования корректности

Для верификации результатов использовался метод перекрестной проверки:

1. **Проверка оператора AND:** Выполнялись запросы А и В по отдельности. Убедились, что список документов для  $A \ \&\& \ B$  является подмножеством обоих отдельных результатов.
2. **Проверка оператора NOT:** Запрос `!java`. Выборочная ручная проверка показала, что в найденных документах слово «java» отсутствует.
3. **Визуальная валидация:** Через веб-интерфейс осуществлялся переход по ссылкам для проверки релевантности контента.

## 7.4 Результаты и производительность

Тестирование проводилось на индексе из ~5000 документов.

**Скорость выполнения:**

- Поиск выполняется мгновенно ( $< 1$  мс) даже для сложных запросов.
- **Причина:** Весь индекс находится в RAM, отсутствуют дисковые операции (Disk I/O) в момент поиска.

**Анализ «сложных» запросов:**

В ТЗ требовалось найти запросы, вызывающие длительную работу. В текущей архитектуре (In-Memory Index) таких запросов практически нет. Задержка может возникнуть только при запросе очень распространенных слов (стоп-слов) в комбинации с оператором `||` (OR), когда результирующий список содержит почти все документы базы (например, `и || в || на`), так как основное время тратится на вывод 5000 ссылок в консоль, а не на поиск.

## 7.5 Примеры запросов

### 1. Запрос: компьютер

- Найдено: 699 док.
- Статус: Успешно. Выдача релевантна.

### 2. Запрос: `linux && python`

- Найдено: 4509 док.
- Анализ: Аномально большой результат вызван особенностями верстки сайта `Навр` (сквозные блоки навигации в футере, которые попали в индекс). Требуется улучшение очистки HTML в ЛР1.

### 3. Запрос: `!java`

- Найдено: 4512 док.
- Статус: Успешно. Из 5000 документов отсеяно ~500, содержащих слово Java.

## 7.6 Вывод

Реализована полнофункциональная поисковая система. Использование бинарного индекса и булевой алгебры на отсортированных списках обеспечило максимальную производительность поиска.